

Institución

Instituto Tecnologico de las Americas (ITLA)

Materia:

Electiva 1

Tema:

Actividad Modelado de la Base de Datos (DB Analitica)

Nombre:
Queirhol Lopez

Matricula:

2025-1986

Decisiones de diseño

Actividad 3.1 – Modelado de la base de datos analítica · Base de datos: `SistemaOpinionesDW` · Motor: MySQL 8.4

1. Objetivo del modelo

La empresa recopila opiniones de sus clientes por tres canales: encuestas internas (CSV), reseñas del sitio web y comentarios en redes sociales. El modelo analítico consolida esa información para responder preguntas de negocio como cuántas opiniones hay, qué productos satisfacen más, cómo evoluciona la percepción en el tiempo y qué canal genera más opiniones negativas.

Este modelo está diseñado para consultar y agregar: pocas uniones, atributos descriptivos agrupados en dimensiones y medidas numéricas concentradas en las tablas de hechos.

2. Modelo elegido: constelación de hechos

La primera idea fue un modelo estrella clásico con una única tabla `FactOpinion` que mezclara las tres fuentes. Se descartó porque cada fuente mide cosas distintas:

Fuente	Puntaje	Clasificación	Cliente
Encuesta	1 a 5 (`PuntajeSatisfaccion`)	Explícita en el CSV	Obligatorio
Reseña web	`Rating` de 1 a 5	No viene; se deriva del Rating	Obligatorio
Comentario social	No tiene	No tiene	Opcional (88 de 200 son anónimos)

Una sola tabla habría obligado a llenar de `NULL` columnas que no aplican a cada fuente. La solución fue una **constelación de hechos** (fact constellation): **tres tablas de hechos** que comparten **cinco dimensiones conformadas**. Sigue siendo un esquema en estrella, repetido una vez por proceso de negocio.

3. Tablas de hechos

Tabla	Qué representa una fila	Medida
FactEncuesta	Una encuesta de satisfacción	PuntajeSatisfaccion (1-5)
FactResenaWeb	Una reseña publicada en el sitio web	Rating (1-5)
FactComentarioSocial	Un comentario en una red social	Ninguna (se cuenta como evento)

Cada hecho conserva además el `Comentario` original y la clave natural del origen (`IdOpinionNK`, `IdReviewNK`, `IdCommentNK`) para poder auditar cualquier fila contra el CSV.

4. Dimensiones conformadas

Son conformadas porque las mismas filas y el mismo significado sirven a las tres tablas de hechos, lo que permite comparar canales sin duplicar catálogos.

Dimensión	Contenido	Origen
DimTiempo	Fecha, año, trimestre, mes, nombre del mes, día, día de la semana, fin de semana	Calendario generado (2024-2026)
DimProducto	Nombre y categoría	products.csv
DimCliente	Nombre y correo	clients.csv
DimFuente	Tipo de canal y plataforma (5 combinaciones)	Columna de fuente de cada CSV
DimClasificacion	Positiva, Neutra, Negativa	Catálogo fijo

Decisión sobre DimFuente. No es una copia de fuente_datos.csv, porque para el análisis interesa el canal y no cada identificador de carga. Se modeló como tipo de canal más plataforma: Encuesta/EncuestaInterna, Web/Web y Red Social/Instagram, Facebook o Twitter.

Decisión sobre DimClasificacion. Se separó en una dimensión propia en lugar de un texto dentro del hecho, para filtrar y agrupar por sentimiento con una unión pequeña y una clave de un solo byte.

5. Claves

- **Claves sustitutas (surrogate).** Cada dimensión usa una clave entera (IdProductoKey, IdClienteKey…) que son las que referencian los hechos. Aíslan al almacén de cambios en los identificadores del sistema origen y hacen las uniones más rápidas.
- **Claves naturales (...NK).** Se conserva el identificador original (P001, C001) con restricción UNIQUE, para trazabilidad y para relacionar el almacén con el modelo transaccional.
- **IdTiempoKey con formato AAAAMMDD.** Es la excepción: no es autoincremental sino calculada (por ejemplo 20250615). Permite filtrar por rango de fechas sin hacer unión y es legible a simple vista.
- **DimClasificacion y DimTiempo sin AUTO_INCREMENT.** Sus claves tienen significado propio y las define el script.

6. Integridad referencial

- Cada tabla de hechos declara una clave foránea hacia cada dimensión que le aplica: 5 en FactEncuesta, 5 en FactResenaWeb y 4 en FactComentarioSocial (sin clasificación). En total, 14 claves foráneas.
- ON DELETE RESTRICT en todas. En un almacén de datos nunca debe poder borrarse una dimensión que tiene hechos asociados, porque se perdería el historial analítico. ON UPDATE CASCADE se mantiene por consistencia con el modelo transaccional.
- Valores faltantes. FactComentarioSocial.IdClienteKey admite NULL porque hay comentarios de usuarios no identificados. En lugar de inventar un cliente genérico, se conserva la ausencia real del dato.
- Reglas de dominio (CHECK). Puntaje y rating entre 1 y 5, trimestre entre 1 y 4, mes entre 1 y 12, comentarios no vacíos. MySQL no permite CHECK sobre columnas que participan en una clave foránea con acciones referenciales, por lo que la coherencia entre clasificación y puntaje queda a cargo del proceso de carga.

7. Normalización

Las **tablas de hechos** están normalizadas: solo contienen claves y medidas. Las **dimensiones** se desnormalizan a propósito (por ejemplo, la categoría vive dentro de DimProducto en lugar de una tabla Categoria aparte). Se evitó el copo de nieve (snowflake) porque agregar uniones solo para ahorrar unos pocos bytes complica las consultas analíticas, que es lo contrario de lo que busca este modelo.

8. Clasificación derivada de las reseñas

Las reseñas web traen un Rating pero no una clasificación. Para que sean comparables con las encuestas, se deriva con la misma regla que ya usa el modelo transaccional: 4 y 5 son Positiva, 3 es Neutra y 1 y 2 son Negativa. Los comentarios sociales no se clasifican, porque la fuente no trae información suficiente y no se asigna un sentimiento sin evidencia.

9. Criterios de análisis

- **Porcentaje de satisfacción** = positivas ÷ opiniones clasificadas × 100. Los comentarios sociales quedan fuera del denominador para no tratarlos como neutros o negativos.
- **Puntaje promedio general** = promedio de encuestas y reseñas, que comparten la escala de 1 a 5.
- **Vistas analíticas.** Se crearon 14 vistas: 4 para los indicadores de reseñas y 10 para las preguntas generales. Una vista base, vw_OpinionesUnificadas, une los tres hechos con `UNION ALL` y alimenta al resto.
- **Índices compuestos** (IdProductoKey, IdTiempoKey) en cada hecho, porque el patrón más frecuente es la tendencia de un producto en el tiempo.

10. Limitaciones reconocidas

Pregunta del enunciado	Limitación
Satisfacción por país, edad o tipo de cliente	Los CSV de clientes solo traen nombre y correo. El modelo queda preparado para añadir esos atributos a `DimCliente` cuando existan
Eventos o campañas que generaron más comentarios	No hay una tabla de eventos. Se detectan los picos por mes y se contrastan con un calendario externo
Palabras clave asociadas a opiniones positivas o negativas	Es opcional (NLP). El texto se conserva en cada hecho para un análisis futuro
Diferencia de tono por canal	Solo es comparable entre encuestas y reseñas web, los únicos canales con clasificación

11. Estructura de scripts y diagrama

Los scripts se ejecutan en este orden y son re-ejecutables:

1. 01_Creation.sql: base de datos y limpieza.
2. 02_DataMaster.sql: las cinco dimensiones y la carga del calendario.
3. 03_DataTransactional.sql: las tres tablas de hechos.
4. 04_Constraints.sql: claves foráneas, reglas CHECK e índices.

5. 05_AnalyticalViews.sql: las 14 vistas.

El diagrama entidad-relación se genera por ingeniería inversa en MySQL Workbench.

Cómo el modelo responde cada pregunta – Guía de consultas

Cada pregunta se responde consultando una de las 14 vistas creadas en DW_05_Vistas_Analiticas.sql.

Parte A – Indicadores de reseñas.

Se calculan sobre FactResenaWeb, que es la entidad reseña.

Indicador	Cálculo del profesor	Vista y columna
Total de reseñas	COUNT	vw_ResenasResumen.TotalResenas
Reseñas positivas	COUNT filtrado	vw_ResenasResumen.ResenasPositivas
Reseñas negativas	COUNT filtrado	vw_ResenasResumen.ResenasNegativas
Reseñas neutras	COUNT filtrado	vw_ResenasResumen.ResenasNeutras
% de satisfacción	Positivas / Total × 100	vw_ResenasResumen.PorcentajeSatisfaccion
Calificación promedio	AVG(Puntuación)	vw_ResenasResumen.CalificacionPromedio
Reseñas por producto	GROUP BY Producto	vw_ResenasPorProducto
Tendencia de reseñas	GROUP BY Fecha	vw_ResenasTendenciaDiaria (por fecha) y vw_ResenasTendencia (por mes)

Parte B – Preguntas del enunciado

1. Análisis general de comentarios

Pregunta	Respuesta
¿Cuántos comentarios se han procesado en total?	vw_ResumenGeneral.TotalOpiniones
¿Cuál es el promedio de satisfacción general?	vw_ResumenGeneral.PuntajePromedioGeneral (promedia encuestas y reseñas; los comentarios sociales no tienen puntaje)
¿Cuántos comentarios por fuente de datos?	vw_ComentariosPorFuente, o las columnas TotalEncuestas, TotalResenasWeb y TotalComentariosSociales de vw_ResumenGeneral
¿Qué porcentaje son positivos, negativos o neutros?	vw_DistribucionClasificacion

2. Opiniones por producto

Pregunta	Respuesta
¿Producto con mayor número de comentarios?	vw_ResumenPorProducto ordenada por TotalOpiniones
¿Productos con mejor calificación promedio?	vw_ResumenPorProducto ordenada por PuntajePromedio
¿Productos con más opiniones negativas?	vw_ResumenPorProducto ordenada por Negativas
¿Cómo ha variado la satisfacción de cada producto en el tiempo?	vw_SatisfaccionProductoMensual filtrada por producto
¿Porcentaje de satisfacción por producto?	vw_ResumenPorProducto.PorcentajeSatisfaccion

3. Opiniones por cliente o segmento

Pregunta	Respuesta
¿Qué clientes realizan más comentarios o encuestas?	vw_ActividadPorCliente (ya viene ordenada de mayor a menor)
¿Qué grupos (país, edad, tipo) muestran mayor satisfacción?	No se puede responder con estos datos. clients.csv solo trae nombre y correo
¿Existen patrones según ubicación o tipo de cliente?	No se puede responder por la misma razón

Los comentarios sociales anónimos no se atribuyen a ningún cliente, por lo que esta vista solo cuenta actividad de clientes identificados.

4. Tendencias y evolución temporal

Pregunta	Respuesta
¿Cómo cambió la percepción mes a mes o trimestre a trimestre?	vw_TendenciaGeneral (mensual) y vw_TendenciaTrimestral
¿Qué eventos generaron más comentarios?	Se detectan los picos de volumen en vw_TendenciaGeneral y se contrastan con un calendario externo de campañas o lanzamientos. El conjunto de datos no incluye eventos
¿Mejora o deterioro de la satisfacción general?	Columnas PuntajePromedio y PorcentajeSatisfaccion de vw_TendenciaGeneral

5. Clasificación de sentimientos

Pregunta	Respuesta
¿Cuántas opiniones fueron positivas, negativas o neutras?	vw_DistribucionClasificacion.Total
¿Qué palabras clave se asocian a cada sentimiento?	Opcional (NLP). El texto original está en la columna Comentario de cada hecho; ver el ejemplo básico abajo
¿Qué porcentaje del total son positivas?	vw_ResumenGeneral.PctPositivasSobreTotal (sobre todos los comentarios) y PctPositivasSobreClasificadas (sobre los que tienen sentimiento)

6. Comparativas entre canales

Pregunta	Respuesta
¿Qué canal genera más comentarios?	vw_ComentariosPorFuente o vw_ComparativaCanales.TotalOpiniones
¿Hay diferencia de tono según el canal?	vw_ComparativaCanales.PorcentajePositivas y PorcentajeNegativas, solo comparables entre Encuesta y Web
¿Qué canal tiene mayor proporción de comentarios negativos?	vw_ComparativaCanales.PorcentajeNegativas, filtrando canales con Clasificadas > 0